Извличане на биомедицинска информация

Проектно предложение: Разпознаване на същности в научната литература за връзката “черва-мозък” въз основа на GutBrainIE @ CLEF 2026.

Явор Чамов №4MI3400787

Контекст: Връзката “черва-мозък”

Тема на проекта

- Изследване на връзката между чревния микробиом и неврологични състояния

Проблем

- В PubMed има голям обем научни публикации по темата
- Информацията в тях е ценна, но често е представена като неструктуриран текст
- Това затруднява бързото намиране и използване на важни медицински знания

Цел

- Да се разработи NLP система за автоматично извличане на знания от научни текстове
- Системата да преобразува неструктурираната информация в структуриран вид
- Резултатите да подпомагат медицинските експерти при анализ и вземане на решения

Фокус на проекта

6.1.1

ОСНОВНА ПОДЗАДАЧА

Разпознаване на именувани субекти

Класическа задача за "маркиране на последователност"

Вход: Заглавия и абстракти от PubMed

Изход: Идентифицирани текстови фрагменти и техните класификационни етикети

Обучаващи колекции от данни

Gold Collection

Експертно анотирани данни от специалисти. Гарантират най-високо качество и прецизност за оценка и фино настройване (639 документа)

Silver Collection

Анотации, създадени от обучени студенти под експертен надзор. Включва и данни от предходната 2025 година (над 1300 документа)

Bronze Collection

Най-масивната колекция (2,972 документа). Генерирана напълно автоматично чрез "distant supervision" без ръчна ревизия

Формат на данните

JSON Формат

Обучаващите данни са организирани в JSON структура (налична и като CSV), където всеки запис отговаря на PubMed статия (PMID).
Включва обекти: **Metadata** (автори, година), **Entities** (същности) и **Relations** (връзки).

Тестови данни

Това са "скрити" документи, върху които ще се извършва финалната оценка на нашия модел.
Тестовият сет съдържа единствено **PMID**, **Заглавие** и **Абстракт**. Нашата система трябва да предскаже всичко останало.

Структура на същностите

Поле	Описание на изискването
start_idx	Начална позиция (символ) на същността в текста
end_idx	Крайна позиция (символ) на същността в текста
location	Къде се намира същността - в заглавието или абстракта
text_span	Точният извлечен текстов фрагмент (напр. "intestinal microbiome")
label	Класификационната категория (напр. "microbiome", "bacteria")

Практически пример: Подзадача 6.1.1

1. ВХОД ОТ PUBMED (МОДЕЛЪТ ПОЛУЧАВА)

```
{
  "38860943": {
    "title": "Probiotics and microbial metabolites
maintain...",
    "abstract": "Amyotrophic lateral sclerosis (ALS) is
a..."
  }
}
```

2. ИЗХОД ОТ МОДЕЛА (КОНЦЕПТУАЛНО)

```
Probiotics                    -> dietary supplement
microbial metabolites         -> chemical
Amyotrophic lateral sclerosis -> DDF
ALS                           -> DDF
```

3. ФИНАЛЕН ИЗХОД (КОНВЕРТИРАН В JSON)

```
{
  "38860943": {
    "entities": [
      {
        "start_idx": 0, "end_idx": 9,
        "location": "title", "text_span": "Probiotics",
        "label": "dietary supplement"
      },
      {
        "start_idx": 15, "end_idx": 35,
        "location": "title", "text_span": "microbial
metabolites",
        "label": "chemical"
      },
      ...
    ]
  }
}
```

Процес на разпознаване

1. Входни данни

Неструктуриран медицински текст, извлечен от заглавията и абстрактите на официалните колекции с данни на GutBrainIE (Gold, Silver, Bronze)

2. NLP Модел

Използване на специализирани архитектури като BioBERT или PubMedBERT, които са предварително обучени върху огромни масиви от биомедицинска литература

3. Изходни данни

Точна локализация (start_idx, end_idx) на медицинските термини и тяхното категоризиране в 13 предварително дефинирани класа

Архитектура

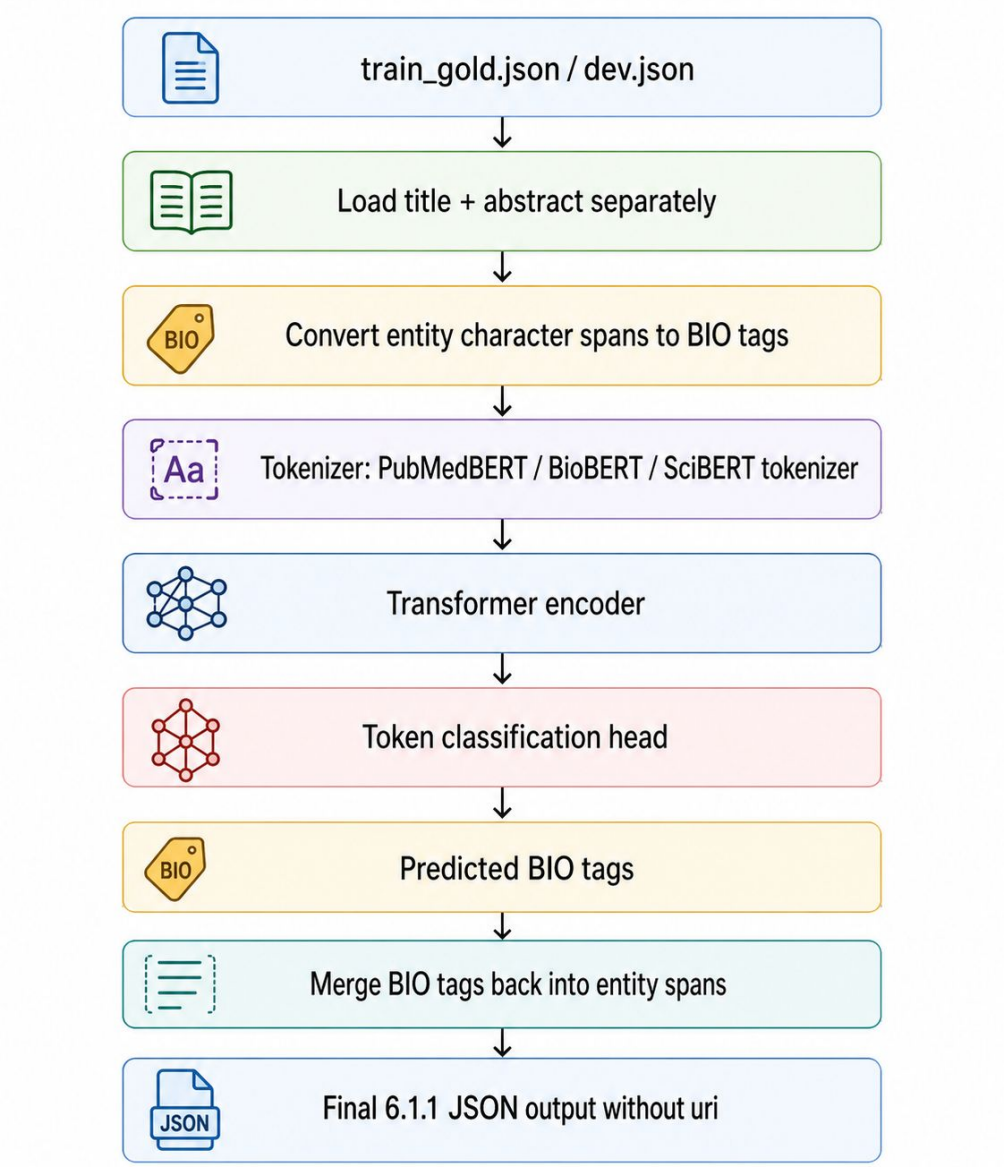

Основни категории за извличане

Bacteria

Бактериални организми и едноклетъчни прокариотни микроорганизми.

DDF

Disease, Disorder, or Finding - Болести, разстройства и клинични находки.

Chemical & Drug

Химични вещества, метаболити, невротрансмитери и терапевтични субстанции.

Gene & Microbiome

Функционални единици на наследствеността и микроорганизмите в тяхната среда.

Опционално разширение на проекта

Подзадача 6.2.1: M-RE

Извличане на връзки на ниво споменаване (Mention-Level Relation Extraction). Това е логична следваща стъпка, която се изпълнява само след успешно работещ NER модел.

Логика на връзките

Системата генерира двойки от намерените същности и класифицира връзката между тях. Например откриване на факта, че дадена **Бактерия** *влияе на* специфична **Болест**.

Разширение: Подзадача 6.2.1 (M-RE)

Извличане на връзки (Relation Extraction)

Надграждаме NER модела. Задачата е да класифицираме семантичната връзка между две вече идентифицирани същности в рамките на едно изречение или абстракт.

Вход: Текст + Списък с открити същности (от 6.1.1).
Изход: Двойки същности (Субект, Обект) и тип на връзката.

Основни типове връзки

- **Влияние върху болест:** Бактерия/Химикал ➔ *намалява/причинява* ➔ DDF (Болест)
- **Производство:** Бактерия ➔ *произвежда* ➔ Химикал/Метаболит
- **Биологична регулация:** Микробиом ➔ *регулира* ➔ Ген/Протеин
- **Корелация:** Същност А ➔ *свързана с (associated with)* ➔ Същност Б

Разширение: Подзадача 6.2.1 (M-RE)

Извличане на връзки

Класифициране на семантичната връзка между две вече идентифицирани същности в рамките на едно изречение или абстракт

Вход: Текст + Списък с открити същности (от 6.1.1)

Изход: Двойки същности (Субект, Обект) и тип на връзката

Основни типове връзки

- **Влияние върху болест:** Бактерия/Химикал ➔ *намалява/причинява* ➔ DDF (Болест)
- **Производство:** Бактерия ➔ *произвежда* ➔ Химикал/Метаболит
- **Биологична регулация:** Микробиом ➔ *регулира* ➔ Ген/Протеин
- **Корелация:** Същност А ➔ *свързана с (associated with)* ➔ Същност Б

Практически пример: Подзадача 6.2.1

1. ВХОД КЪМ ТРАНСФОРМЪР МОДЕЛА

Моделът получава текст, в който дадена двойка същности е маркирана:

```
This study proposes that the [SUBJ] gut microbiome [/SUBJ]
differs based on the [OBJ] clinical phenotype [/OBJ]...
```

2. ЛОГИКА НА КЛАСИФИКАТОРА

```
Възможни двойки кандидати:
gut microbiome + clinical phenotype ➔ is linked to
gut microbiome + frailty            ➔ no-relation
frailty + Japanese individuals      ➔ target
```

3. ФИНАЛЕН ИЗХОД (JSON ФОРМАТ)


```
{
  "39599625": {
    "mention_level_relations": [
      {
        "subject_start": 1160,
        "subject_end": 1174,
        "subject_location": "abstract",
        "subject_text_span": "gut microbiome",
        "subject_label": "microbiome",
        "predicate": "is linked to",
        "object_start": 1201,
        "object_end": 1219,
        "object_location": "abstract",
        "object_text_span": "clinical phenotype",
        "object_label": "DDF"
      }
    ]
  }
}
```

Архитектура

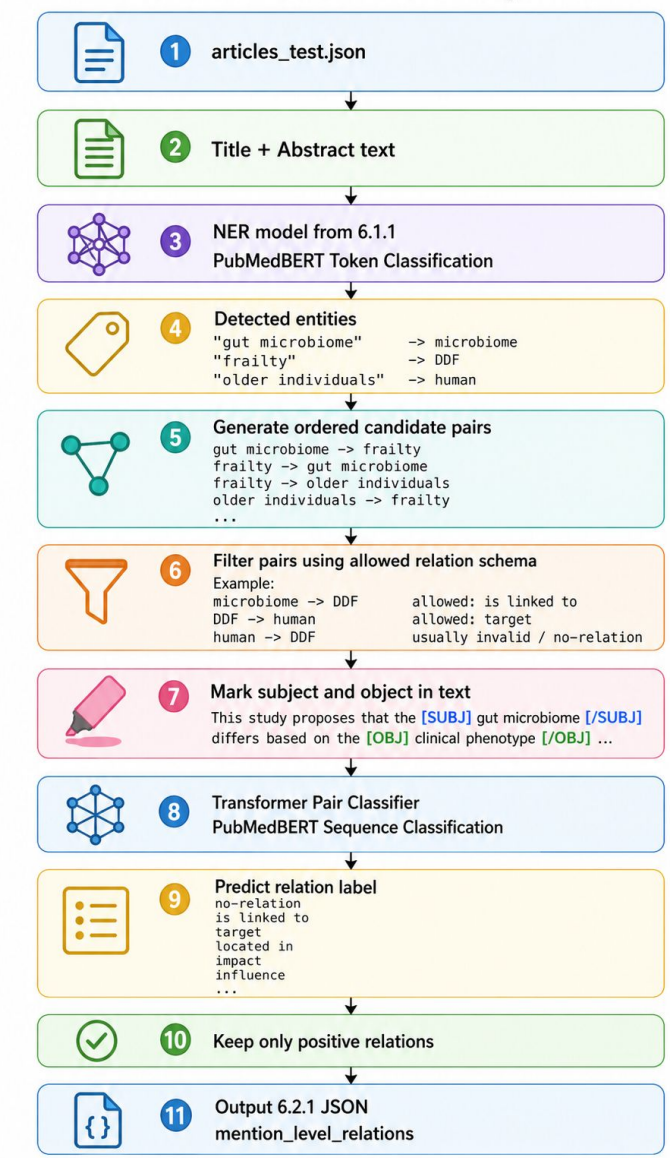

Оценка на резултатите

Стандартни метрики

Всички подзадачи се оценяват чрез класически метрики за извличане на информация:

- **Macro-average** precision, recall и F1-score
- **Micro-average** precision, recall и F1-score

Основна метрика: Micro-F1

Официалната референтна метрика за класиране в лидерборда е **Micro-average F1-score**

План за изпълнение

Фаза 1: Базов модел

Анализ на данните и изграждане на базов модел

Фаза 2: Моделиране

Имплементация на Transformer-базиран модел (BioBERT/SciBERT) за NER задачата

Фаза 3: Оценка

Тестване на модела върху Development set и изчисляване на Precision, Recall и F1-score

Фаза 4: Разширение

Интеграция на модул за извличане на връзки (Relation Extraction).