

Хибридна система за препоръчване на аниме

Курсов проект по "Препоръчващи системи"

Изготвил: Явор Чамов

Преподавател: д-р Милен Чечев

№: 4MI3400787

| Цели на проекта

Основна идея

- Изграждане на хибридна система за персонални препоръки на аниме
- Практическо приложение на ключови алгоритми за препоръчване

Алгоритмични цели

- Неперсонализирани: Популярност и претеглена средна оценка (damped mean)
- Content-Based: Профилиране по жанр, тип и метаданни (TF-IDF/Cosine Similarity)
- Collaborative Filtering: Сътрудничество чрез потребителска и артикулна близост
- Матрична факторизация: Прогнозиране на рейтинги чрез латентни фактори (SVD)
- Хибридизация: Комбиниране на моделите в обща скоринг система

Структура на данните

Взаимодействия

anime_ratings.dat: Явни оценки (1-10) от потребители.

anime_history.dat: Индиректна история на гледане (Binary interactions).

Метаданни за аниме

anime_info.dat: Детайлна информация за заглавията:

- Жанр и тип (Movie, TV, OVA)
- Брой епизоди и рейтинг
- Брой членове на общността

| Мащаб на данните

420k

Оценки (Ratings)

7,000+

Аниме заглавия

Проектът обработва данни за над 5,000 активни потребители.

Базови неперсонализирани модели

-  **Най-популярни заглавия:** Ранкинг базиран на общия брой взаимодействия.
-  **Среден рейтинг:** Класация според средната оценка на потребителите.
-  **Damped Mean Rating:** Корекция на средния рейтинг за заглавия с малко оценки.
-  **Популярност според членовете:** Използване на 'members' метаданни за глобален ранкинг.

| Филтриране по съдържание

Извличане на характеристики (Feature Engineering)

- Текстова обработка: Прилагане на TF-IDF върху жанрове и описания
- Категорийни признаци: One-hot encoding за формат на излъчване (TV, Movie, OVA)
- Числови метаданни: Нормализация на брой епизоди, общ рейтинг и брой членове в общността
- Векторно представяне: Превръщане на всяко аниме в многомерен вектор от признаци

Потребителско профилиране

- Агрегиране на интереси: Създаване на потребителски профил на базата на векторите на гледаните заглавия.
- Претегляне по оценка: По-високо тегло за характеристиките на анимета, оценени с 9 или 10.

| Филтриране по съдържание

Процес на препоръчване

- Изчисляване на сходство: Косинусова близост (Cosine Similarity) между потребителския вектор и вектора на артикула
- Ранжиране: Подреждане на заглавията по степен на съответствие с профила
- Генериране на обяснения: Възможност за аргументиране: „Препоръчано, защото харесвате Екшън и Фентъзи“

Ключови предимства

- Потребителска независимост: Препоръките не зависят от оценките на други потребители
- Нишови интереси: Успешно откриване на заглавия със специфични характеристики, които не са масово популярни


Колаборативно филтриране

Силата на общността

Откриване на скрити зависимости чрез потребителското поведение:

User-based CF: Намиране на подобни потребители и техните предпочитания

Item-based CF: Препоръчване на заглавия, подобни на вече харесаните от потребителя



Матрична факторизация (SVD)

$$\hat{r}_{u,i} = \mu + b_u + b_i + q_i^T p_u$$

Предимство	Описание
Латентни фактори	Открива скрити теми (напр. "меланхолия", "епични битки") без етикети
Мащабируемост	Справя се добре с много разреждени матрици на оценките
Регуларизация	Предотвратява прекаленото напасване (overfitting) към шума в данните

Индиректна обратна връзка



История

Използване на
'anime_history.dat' за анализ на
гледаемостта.



Top-N

Фокус върху генериране на
списъци, а не само на точен
рейтинг.



Метрики

Оценка чрез Precision@K,
Recall@K и nDCG.

Хибриден модел: Архитектура



Комбиниран резултат (Weighted Hybrid) за оптимален баланс между персонализация и стабилност.

| Хибриден модел: Архитектура

Интеграция на данни и модели

- Мултиизточников вход: Комбиниране на anime_ratings.dat (явни), anime_history.dat (скрити) и anime_info.dat (метаданни)
- Компоненти на системата: Обединяване на неперсонализирани базисни линии, Content-Based Collaborative Filtering и Matrix Factorization
- Цел на хибрида: Минимизиране на грешките (RMSE/MAE) и оптимизиране на топ-N списъците (nDCG/MAP)

Логика на хибридния скоринг

- Тегла: Възможност за настройка на приоритета между латентни фактори, жанрово подобие и популярност
- Предимство: По-добра способност за улавяне на скрити предпочитания спрямо базовите модели

$$Hybrid_Score = \alpha \cdot MF + \beta \cdot CBF + \gamma \cdot Pop.$$


Оценка на производителността



Разширение: Невронно колаборативно филтриране (NeuMF)

Архитектура на модела

- Вход: Вектори с User_ID и Anime_ID
- Embedding слоеве: Латентни представяния на потребители и анимета
- GMF клон (Generalized Matrix Factorization): Елемент по елемент (element-wise) произведение за улавяне на линейни зависимости
- MLP клон (Multi-Layer Perceptron): Конкатенация и преминаване през плътни (dense) слоеве за нелинейни връзки
- Изход: Прогнозиран резултат за предпочитание (preference score)



Въпроси?